

Dalia Salih, Advances in AI

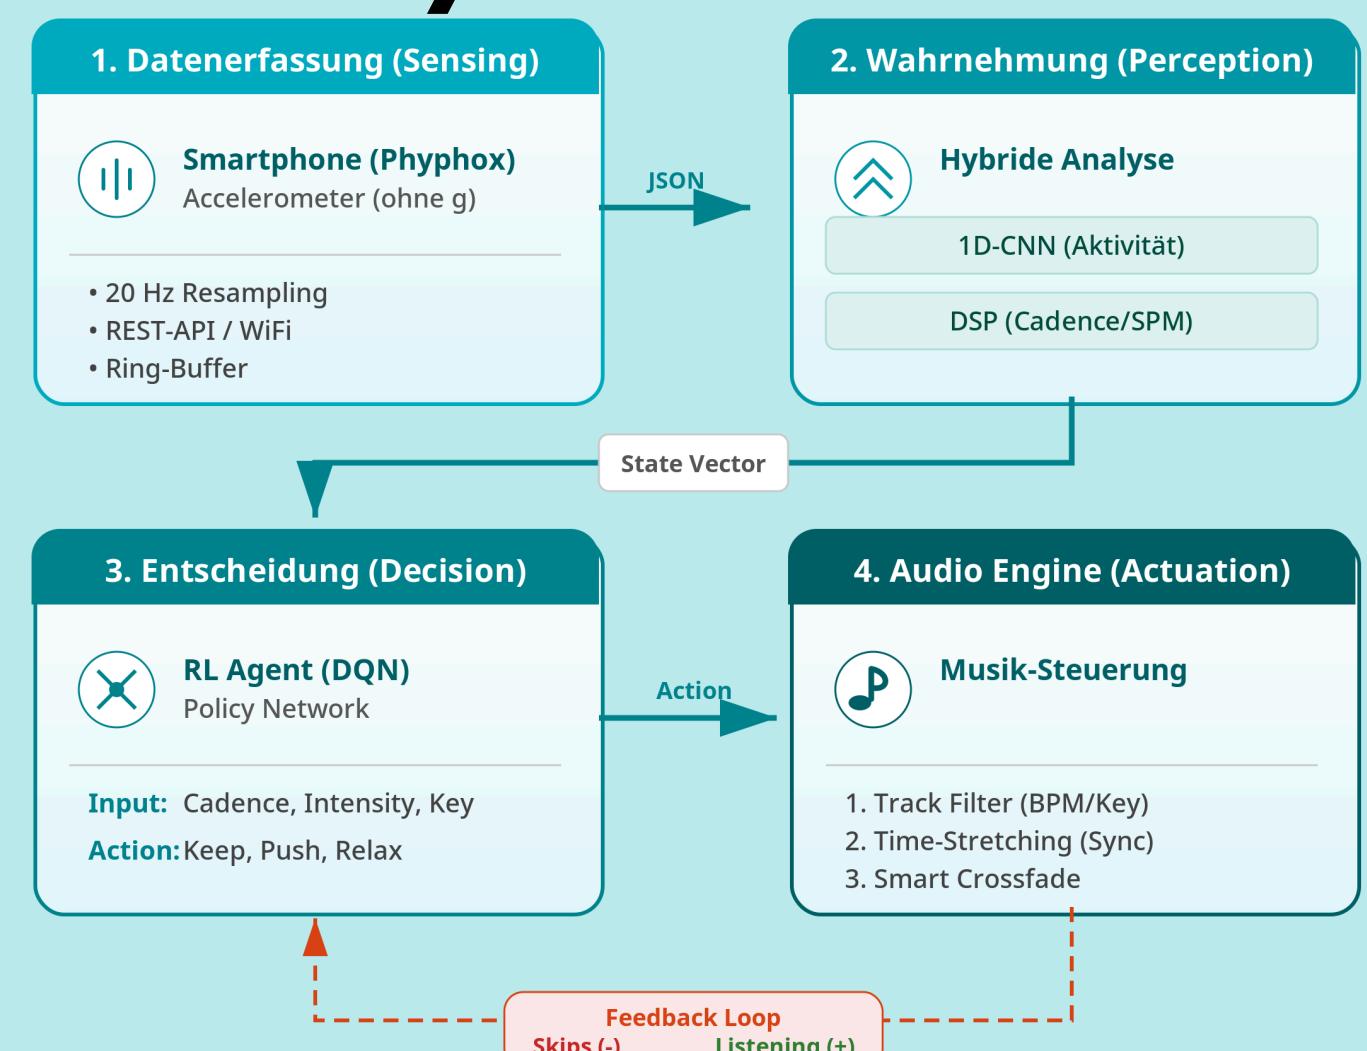
Problemstellung

Viele Lauf-Apps nutzen starre Regeln und ignorieren Intensität/Ermüdung.
Reines BPM-Matching reicht nicht: ohne Key-Match und Beat-Alignment wirken Übergänge musikalisch unsauber.
Außerdem sind Musikpräferenzen individuell. Ein System sollte adaptiv auf Nutzer-Feedback (Skips) reagieren.

Motivation

BPM-Buddy agiert wie ein intelligenter DJ: Es "fühlt" über Smartphone-Sensoren, wie der Nutzer läuft, und wählt adaptiv Musik, die Motivation & Pace unterstützt. Statt statischer Regeln lernt ein RL-Agent, welche Tracks für Tempo- und Intensitätszustände am besten funktionieren.

Systemüberblick



01 >>

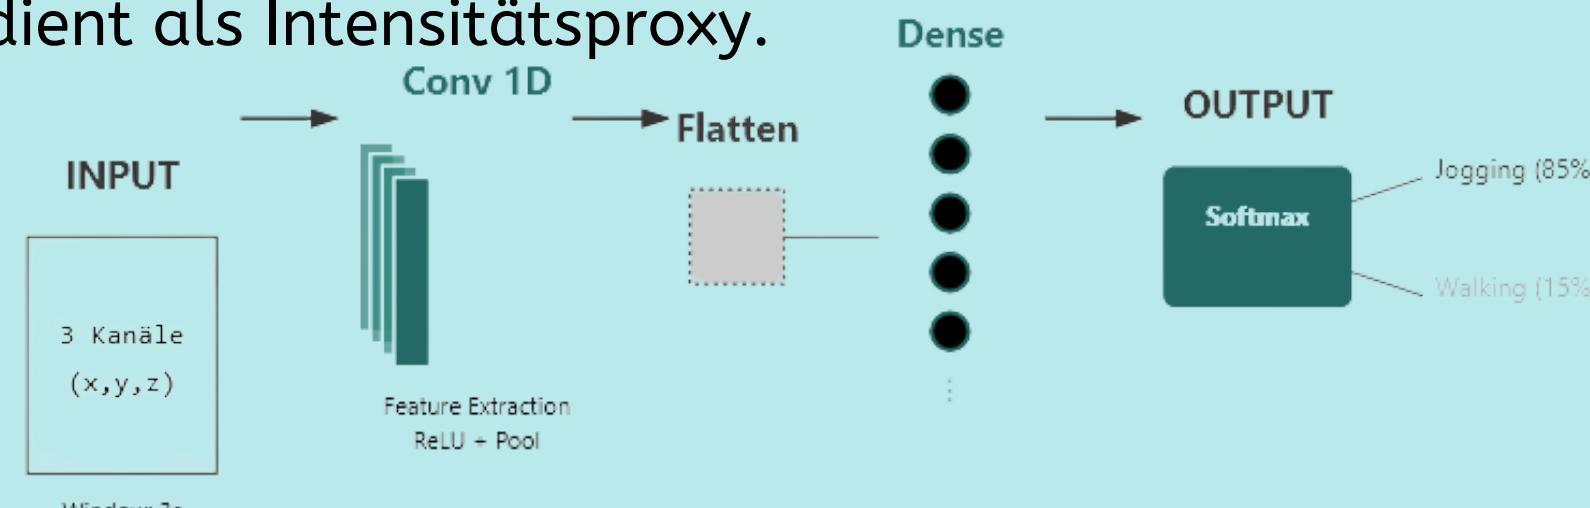
Datenerfassung

Ein Smartphone streamt Beschleunigungsdaten über **Phyphox** als REST-Server im lokalen Netzwerk. Der Laptop sendet hochfrequente HTTP-GET-Requests und erhält JSON-Datenblöcke (Buffered Streaming). Das reduziert Datenverlust bei kurzen WLAN-Drops und liefert wissenschaftlich etablierte Rohdaten.

02 >>

Wahrnehmung

Ein **1D-CNN** (PyTorch), trainiert auf **WISDM v1.1**, verarbeitet Sliding-Windows (3 s, auf 20 Hz resampled) und **klassifiziert Aktivitäten** (z. B. Jogging vs Walking; Standing/Sitting als Ruheklassen). Zusätzlich werden Cadence und Confidence über DSP (Autokorrelation/ Peak-Detektion) geschätzt. Ein Signal-Energie-Maß dient als Intensitätsproxy.



03 >>

Entscheidung und Ausführung

Ein **Deep-Q-Network** wählt Aktionen basierend auf einem Zustand aus Cadence, Intensität und Track-Metadaten (Tempo/Key). Vor der Auswahl filtert das System Kandidaten über BPM-Toleranz und Key-Kompatibilität (harmonic mixing/Camelot). Die Audio-Engine setzt Crossfades um.

Referenzen

Das CNN erreicht eine Test-Accuracy von **>98%**. Die klare Separation der Klassen Jogging und Walking belegt die Robustheit gegenüber Sensorrauschen.

		CNN Accuracy (in %)			
		Jogging	Sitting	Standing	Walking
Wahre Aktivität	Erkannte Aktivität	98.5	0.0	0.5	1.0
		0.0	96.2	3.8	0.0
Standing	Erkannte Aktivität	0.0	2.5	97.5	0.0
		0.5	0.0	0.0	99.5

Im Test reduziert die Reinforcement-Learning-Policy den mittleren BPM-Fehler gegenüber einer heuristischen Baseline und senkt die Anzahl der Trackwechsel pro Minute. Dies zeigt, dass RL nicht nur präziseres Tempo-Matching ermöglicht, sondern auch stabilere und nutzerfreundlichere Musikentscheidungen trifft.



Fazit

BPM-Buddy zeigt eine End-to-End Echtzeit-Pipeline, die Bewegung erkennt, Cadence schätzt und Musik regelkonform (Tempo/Key/Beat) anpasst. RL erlaubt individuelle Präferenzanpassung über Feedback (Skips).

Nächste Schritte: User-Study, Robustheit gegen Handyposition, feinere Reward-Funktion.

